



# PRINCIPAL COMPONENT ANALYSIS(PCA)

**Ana Fikir:** Daha az boyutlu uzayda daha doğru veri temsili elde etmek olasıdır.




En geniş variance (değişim) aralığında uzanan tek boyutlu bir değişken (çizgi) verilerimizi en doğru temsil edebilen bir yapı olacaktır.

Verilerimizi eniyi temsil edebilecek tek boyutlu yapı tesit edildikten sonra  $y$  vektörü ile temsil edilecek bir boyutlu koordinat sistemine transfer edilmeye ihtiy




$y$  nin yeşil çizgi boyunca uzanan eski  $x$  verileriyle aynı variance sahip olduğu bilinmektedir.


PCA verideki en büyük değişimi korur. Şimdi bu durumu açıklayacağız.



*best 2D approximation*




*best 1D approximation*



## 3 boyutta eliptik bulut yaklaşımı

# PCA

- Verideki en büyük değişimin yönü nedir?
- Eğer **X** çoklu değişim dağılımı  $N(\mu, \Sigma)$  na sahipse, enbüyük değişimin yönü enbüyük özdeğere ait özvektör tarafından belirlenir.



Bu bizim verinin kovaryans matrisinde bakabileceğimiz nicelik için bir ip ucudur. (PCA Gaussian dağılımın dışındaki dağılımlara da uygulanabilir.)


# PCA : Türev için Lineer Cebir

- $\mathbf{V}$ ,  $d$  boyutlu bir lineer uzay ve  $\mathbf{W}$ ,  $k$  boyutlu ve  $\mathbf{V}$  nin bir altuzayı olsun.
- $\mathbf{W}$  için ortonormal bazlar  $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k\}$  oluşan  $d$  boyutlu vektör kümesi her zaman bulabiliriz.

$$\langle \mathbf{e}_i, \mathbf{e}_j \rangle = 0 \quad \text{eğer } i \neq j; \quad \langle \mathbf{e}_i, \mathbf{e}_i \rangle = 1$$

Böylece  $\mathbf{W}$  alt uzayındaki herhangi bir vektör aşağıdaki gibi yazılabilir

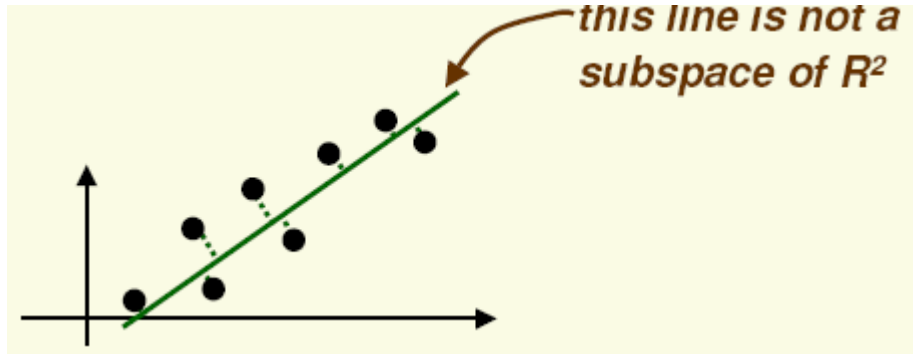
$$\alpha_1 \mathbf{e}_1 + \alpha_2 \mathbf{e}_2 + \dots + \alpha_k \mathbf{e}_k = \sum_{i=1}^k \alpha_i \mathbf{e}_i \quad \text{for scalars } \alpha_1, \dots, \alpha_k$$




Let  $\mathbf{V} = \mathbf{R}^2$  and  $\mathbf{W}$  be the line  $x-2y=0$ . Then the orthonormal basis for  $\mathbf{W}$  is

$$\left\{ \begin{bmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{bmatrix} \right\}$$

**W** uzayının sıfır vektörünü içerdiğini farzedelim. bu durumda orijinden geçecektir.



Türev için, **W** alt uzayına geçmek uygun olacaktır; herşeyi kaydırmamız gerekecektir.




# PCA Türev: Ortalama Vektör Kadar Kaydırma

PCA dan önce veriden ortalama örneğini çıkart

$$x - \frac{1}{n} \sum_{i=1}^n x_i = x - \hat{\mu}$$

Yeni veriler sıfır ortalamaya sahip  $E(X - E(X)) = E(X) - E(X) = 0$

Burada bütün yaptığımız koordinat sistemini değiştirdik.



Başka bir açıdan **Y** yi elde etmenin ilk adımı **X** in ortalamasını çıkartmak olmuştur.

$$x \rightarrow y = f(x) = g(x - \hat{\mu})$$



# PCA Türev


Biz  $k < d$  boyutlu bir  $W$  altuzayında verimizi  $D = \{x_1, x_2, \dots, x_n\}$  temsilini arıyoruz

•  $\{e_1, e_2, \dots, e_k\}$   $W$  altuzayının ortonormal bazları olsun.  $W$  altuzayındaki herhangi bir vektör  $\sum_{i=1}^k \alpha_i e_i$  şeklinde yazılabilir.

• Böylece  $x$   $W$  uzayına en yakın vektör  $\sum_{i=1}^k \alpha_{1i} e_i$  şeklinde temsil edilebilir.

$$\text{error} = \left\| x_1 - \sum_{i=1}^k \alpha_{1i} e_i \right\|^2$$

• Bu temsilin hatası  $\text{error}$  şeklinde oluşur.



- Toplam hatayı bulmak için bütün  $x_j$  ler üzerinden toplam alıyoruz

$$\sum_{i=1}^k \alpha_{ji} \mathbf{e}_i$$

- Herhangi bir  $\lambda_j$  şeklinde yazılabilir.

- Böylece bütün  $D$  verilerinin toplam hatası:

$$J(\underbrace{\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}}_{\text{unknowns}}) = \sum_{j=1}^n \left\| \mathbf{x}_j - \sum_{i=1}^k \alpha_{ji} \mathbf{e}_i \right\|^2$$

*sum over all data points*  
 ↓  
*error at one point*

· J yi minimize etmek  $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k\}$  baz vektörlerinin de ortogonal olması gerekliliğininde gözönünde

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}) = \sum_{j=1}^n \left\| \mathbf{x}_j - \sum_{i=1}^k \alpha_{ji} \mathbf{e}_i \right\|^2$$

· Öncelikle J nin açılımını yaparsak

$$\begin{aligned} J(\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}) &= \sum_{j=1}^n \left\| \mathbf{x}_j \right\|^2 - 2 \sum_{j=1}^n \mathbf{x}_j^t \left( \sum_{i=1}^k \alpha_{ji} \mathbf{e}_i \right) + \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji}^2 \\ &= \sum_{j=1}^n \left\| \mathbf{x}_j \right\|^2 - 2 \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji} \mathbf{x}_j^t \mathbf{e}_i + \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji}^2 \end{aligned}$$

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}) = \sum_{j=1}^n \left\| \mathbf{x}_j \right\|^2 - 2 \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji} \mathbf{x}_j^t \mathbf{e}_i + \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji}^2$$

$\alpha_{ml}$  e göre kısmi türev :  $\frac{\partial}{\partial \alpha_{ml}} J(\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}) = -2\mathbf{x}_m^t \mathbf{e}_l + 2\alpha_{ml}$

• Böylece  $\alpha_{ml}$  için optimal değeri şu şekilde elde ederiz.

$$-2\mathbf{x}_m^t \mathbf{e}_l + 2\alpha_{ml} = 0 \Rightarrow \alpha_{ml} = \mathbf{x}_m^t \mathbf{e}_l$$

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k, \alpha_{11}, \dots, \alpha_{nk}) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - 2 \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji} \mathbf{x}_j^t \mathbf{e}_i + \sum_{j=1}^n \sum_{i=1}^k \alpha_{ji}^2$$

•  $\alpha_{ml} = \mathbf{x}_m^t \mathbf{e}_l$  J de yerine yazılırsa

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - 2 \sum_{j=1}^n \sum_{i=1}^k (\mathbf{x}_j^t \mathbf{e}_i) \mathbf{x}_j^t \mathbf{e}_i + \sum_{j=1}^n \sum_{i=1}^k (\mathbf{x}_j^t \mathbf{e}_i)^2$$

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{j=1}^n \sum_{i=1}^k (\mathbf{x}_j^t \mathbf{e}_i)^2$$

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{j=1}^n \sum_{i=1}^k (\mathbf{x}_j^t \mathbf{e}_i)^2$$

- $(\mathbf{a}^t \mathbf{b})^2 = (\mathbf{a}^t \mathbf{b})(\mathbf{a}^t \mathbf{b}) = (\mathbf{b}^t \mathbf{a})(\mathbf{a}^t \mathbf{b}) = \mathbf{b}^t (\mathbf{a} \mathbf{a}^t) \mathbf{b}$

kullanılarak

$$\begin{aligned} J(\mathbf{e}_1, \dots, \mathbf{e}_k) &= \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{i=1}^k \mathbf{e}_i^t \left( \sum_{j=1}^n (\mathbf{x}_j \mathbf{x}_j^t) \right) \mathbf{e}_i \\ &= \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i \end{aligned}$$

- Burada  $\mathbf{S} = \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^t$

• S matrisine saçılma matrisi denilmektedir ve sadece kovaryans matrisinin n- 1 çarpılmışıdır.

$$\hat{\Sigma} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{x}_j - \hat{\mu})(\mathbf{x}_j - \hat{\mu})^t$$

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \underbrace{\sum_{j=1}^n \|\mathbf{x}_j\|^2}_{\text{constant}} - \sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i$$

- J yi minimize etme  $\sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i$  değerini maksimize etmekle eşdeğerdir.
- Bütün i ler için  $\mathbf{e}_i^t \mathbf{e}_i = 1$  şartını koruyarak.
- Lagrange çarpanları yönteminide kullanarak
- yeni bir U fonksiyonunu maksimize etmeliyiz.

$$u(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i - \sum_{j=1}^k \lambda_j (\mathbf{e}_j^t \mathbf{e}_j - 1)$$

• Eğer  $X$  bir vektör  $f(\mathbf{x}) = f(x_1, \dots, x_d)$  ise

bir fonksiyon

$$\frac{d}{d\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_d} \end{bmatrix}$$

olacağı aşikardır

$$\frac{d}{d\mathbf{x}} (\mathbf{x}^t \mathbf{x}) = 2\mathbf{x}$$

bilgisini kullanarak

• Eğer  $A$  bir simetrik matris ise  $\frac{d}{d\mathbf{x}} (\mathbf{x}^t A \mathbf{x}) = 2A\mathbf{x}$  şeklinde kullanılabileceği bilgisine ulaşırız.

$$u(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i - \sum_{j=1}^k \lambda_j (\mathbf{e}_j^t \mathbf{e}_j - 1)$$

- $\mathbf{e}_m$  ye göre kısmi türevini alacak olursak.

$$\frac{\partial}{\partial \mathbf{e}_m} u(\mathbf{e}_1, \dots, \mathbf{e}_k) = 2\mathbf{S}\mathbf{e}_m - 2\lambda_m \mathbf{e}_m = 0$$

- Böylece  $\lambda_m$   $\mathbf{e}_m$   $\mathbf{S}$  matrisinin özdeğer ve özvektörleri olmaktadır.

$$\mathbf{S}\mathbf{e}_m = \lambda_m \mathbf{e}_m$$




$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{i=1}^k \mathbf{e}_i^t \mathbf{S} \mathbf{e}_i$$

- Bunları şimdi tekrar  $J$  de yerine yazalım.

$$J(\mathbf{e}_1, \dots, \mathbf{e}_k) = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{i=1}^k \lambda_i \|\mathbf{e}_i\|^2 = \sum_{j=1}^n \|\mathbf{x}_j\|^2 - \sum_{i=1}^k \lambda_i$$


*constant*

- En büyük özdeğer variance (değişim) in en büyük olduğu yöndeki özvektörle ilintilidir.



# SON ADIM

Nihayi  $Y$  vektörünü elde etmek için koordinat sistemini değiştiriyoruz.



- $E$  matrisini oluşturuyoruz  $E = [e_1 \cdots e_k]$
- Koordinat dönüşümünü yapıyoruz  $y = E^t x$
- Özvektörlerimiz yeni koordinat sistemimizin baz vektörleri oluyor

$$E^t e_i = \begin{bmatrix} e_1 \\ \vdots \\ e_i \\ \vdots \\ e_k \end{bmatrix} e_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

## *Recipe for Dimension Reduction with PCA*


Data  $\mathbf{D}=\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ . Each  $\mathbf{x}_i$  is a  $d$ -dimensional vector. Wish to use PCA to reduce dimension to  $k$

1. Find the sample mean  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$
2. Subtract sample mean from the data  $\mathbf{z}_i = \mathbf{x}_i - \hat{\mu}$
3. Compute the scatter matrix  $\mathbf{S} = \sum_{i=1}^n \mathbf{z}_i \mathbf{z}_i^t$
4. Compute eigenvectors  $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k$  corresponding to the  $k$  largest eigenvalues of  $\mathbf{S}$
5. Let  $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k$  be the columns of matrix  $\mathbf{E} = [\mathbf{e}_1 \cdots \mathbf{e}_k]$
6. The desired  $\mathbf{y}$  which is the closest approximation to  $\mathbf{x}$  is  $\mathbf{y} = \mathbf{E}^t \mathbf{z}$

## PCA Example Using Matlab

- Let  $D = \{(1,2), (2,3), (3,2), (4,4), (5,4), (6,7), (7,6), (9,7)\}$
- Convenient to arrange data in array

$$X = \begin{bmatrix} 1 & 2 \\ \vdots & \vdots \\ 9 & 7 \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_8 \end{bmatrix}$$



- Mean  $\mu = \text{mean}(X) = [4.6 \ 4.4]$
- Subtract mean from data to get new data array  $Z$

$$Z = X - \begin{bmatrix} \mu \\ \vdots \\ \mu \end{bmatrix} = X - \text{repmat}(\mu, 8, 1) = \begin{bmatrix} -3.6 & -4.4 \\ \vdots & \vdots \\ 4.4 & 2.6 \end{bmatrix}$$

- Compute the scatter matrix  $S$

$$S = 7 * \text{cov}(Z) = [-3.6 \ -4.4] \begin{bmatrix} -3.6 \\ -4.4 \end{bmatrix} + \dots + [4.4 \ 2.6] \begin{bmatrix} 4.4 \\ 2.6 \end{bmatrix} = \begin{bmatrix} 57 & 40 \\ 40 & 34 \end{bmatrix}$$


*matlab uses unbiased estimate for covariance, so  $S = (n-1) * \text{cov}(Z)$*

## PCA Example Using Matlab

- Use  $[V,D]=\text{eig}(\mathbf{S})$  to get eigenvalues and eigenvectors of  $\mathbf{S}$

$$\lambda_1 = 87 \text{ and } \mathbf{e}_1 = \begin{bmatrix} -0.8 \\ -0.6 \end{bmatrix}$$

$$\lambda_2 = 3.8 \text{ and } \mathbf{e}_2 = \begin{bmatrix} 0.6 \\ -0.8 \end{bmatrix}$$



- Projection to 1D space in the direction of  $\mathbf{e}_1$

$$\begin{aligned} Y = \mathbf{e}_1^t \mathbf{Z}^t &= \left( \begin{bmatrix} -0.8 & -0.6 \end{bmatrix} \begin{bmatrix} -3.6 & \cdots & 4.4 \\ -4.4 & \cdots & 2.6 \end{bmatrix} \right) = \begin{bmatrix} 4.3 & \cdots & -5.1 \end{bmatrix} \\ &= [y_1 \cdots y_8] \end{aligned}$$